

TRABAJO FINAL · INTRODUCCIÓN A CIENCIA DE DATOS · 2026

Predicción de rotación de personal

Clasificación supervisada para anticipar qué empleados dejan la empresa, sobre el dataset IBM HR Analytics.

INTEGRANTES Pedro Luis Fuentes Prieto · Enzo Saldivia

MATERIA Introducción a Ciencia de Datos

FECHA Junio 2026

DATASET IBM HR Analytics Employee Attrition · 1470 × 35

MODELOS Regresión Logística · Random Forest

■ Objetivo


La idea del trabajo es predecir si un empleado se va a ir de la empresa o no. Eso está en la columna `Attrition`: `Yes` quiere decir que se fue y `No` que se quedó. Como tengo los datos históricos junto con la respuesta, es un problema de **clasificación supervisada**. Para resolverlo entrené y comparé dos modelos que vimos en la materia: **Regresión Logística** y **Random Forest**.

Todo el código está en el notebook `trabajo_final_icd_2026.ipynb`. Acá explico lo que hice y los resultados.

■ Los datos

El dataset tiene **1470 filas y 35 columnas** con información de los empleados: edad, sueldo, puesto, antigüedad, nivel de satisfacción, si hace horas extra, etc.

Lo primero que miré fue cómo está repartida la variable que quiero predecir:



Distribución de Attrition

La mayoría de los empleados se queda: **1233 con No (≈83.9%)** y solo **237 con Yes (≈16.1%)**. Esto es importante porque el dataset está **desbalanceado**, y un modelo podría tener un accuracy alto simplemente diciendo casi siempre `No`. Por eso más adelante no miro solo el accuracy.

■ Exploración


Revisé los valores faltantes y encontré tres columnas con datos vacíos:

Columna	Faltantes
DistanceFromHome	147
DailyRate	73
Age	44

También vi que hay columnas que tienen siempre el mismo valor (`EmployeeCount` , `StandardHours` , `Over18`) y una que es solo un número de legajo (`EmployeeNumber`). Esas no aportan nada para predecir, así que las saco después.

Después hice algunos gráficos para entender mejor los datos.


Salario según si se fue o no (boxplot):



Boxplot del salario

Los que se fueron suelen tener sueldos más bajos: su caja queda más abajo que la de los que se quedaron.


Edad según si se fue o no (violín):



Violín de la edad

Los que se van tienden a ser más jóvenes, se concentran más cerca de los 30 años.


Attrition según horas extra:



Attrition según horas extra

Los empleados que hacen horas extra se van bastante más seguido que los que no.

Mapa de calor de correlaciones:



Mapa de calor

Sirve para ver qué variables se mueven juntas. Por ejemplo, las variables de antigüedad (años en la empresa, en el puesto, con el jefe) están relacionadas entre ellas, y el sueldo va de la mano de la experiencia total. Igual, que dos cosas vayan juntas no significa que una cause la otra: es solo lo que muestran los datos.

■ Preparación de los datos

Primero revisé que no hubiera errores de entrada: no hay filas duplicadas, las edades están todas en un rango razonable (18 a 60 años) y `Attrition` solo tiene los valores `Yes / No`. Así que los datos venían limpios y no hubo que corregir nada.


Después los preparé para el modelo:

- Saqué las columnas que no aportan (las constantes y el legajo).
- Pasé `Attrition` a número (`No = 0`, `Yes = 1`), porque los modelos trabajan con números.
- Convertí las columnas de texto en columnas 0/1 con `get_dummies(drop_first=True)` (one-hot encoding). Quedaron **44 columnas**.
- Dividí en entrenamiento (80%) y prueba (20%) usando `stratify` para mantener la misma proporción de `Yes / No` en las dos partes. Quedaron **1176 filas de entrenamiento y 294 de prueba**.
- Recién ahí rellené los faltantes con la **mediana del conjunto de entrenamiento**: la calculo solo con `train` para no filtrar información del `test`. Uso la mediana porque es robusta y no se deja arrastrar por valores extremos.
- Escalé las variables con `StandardScaler`. La Regresión Logística lo necesita porque es sensible a la escala; al Random Forest no le afecta.

■ Modelos y resultados


Entrené los dos modelos y los evalué sobre el conjunto de prueba (294 empleados, de los cuales 47 eran Yes). Estas fueron las métricas:

Métrica	Regresión Logística	Random Forest
Accuracy	0.8605	0.8401
Precision (Yes)	0.6154	0.5000
Recall (Yes)	0.3404	0.1064
F1 (Yes)	0.4384	0.1754




Comparación de modelos

Las matrices de confusión muestran en qué se equivoca cada modelo (las filas son el valor real y las columnas lo que predijo):



Matriz de confusión - Regresión Logística

La Regresión Logística acertó **253 de los 294** casos. De los 47 empleados que realmente se fueron, detectó **16**. No es mucho, pero es el modelo que más encontró.




Matriz de confusión - Random Forest

El Random Forest acertó **247 de 294**, pero de los 47 que se fueron solo detectó **5**. Casi siempre predice **No**.

Lo interesante es que los dos modelos tienen un accuracy parecido y bastante alto (84–86%), pero eso es en gran parte porque la mayoría de los empleados son **No**. Cuando miro el **recall de la clase Yes** (cuántos de los que se fueron logré encontrar), se nota que a los dos les cuesta, y que la Regresión Logística anda mejor (34% contra 11%).

■ Variables más importantes

El Random Forest deja ver qué variables pesan más para decidir:



Las que más influyen son el sueldo (`MonthlyIncome`), la edad (`Age`), los años trabajados (`TotalWorkingYears`), algunas tarifas (`DailyRate` , `HourlyRate` , `MonthlyRate`) y la distancia al trabajo (`DistanceFromHome`). También aparece `OverTime_Yes` , que coincide con lo que ya había visto en los gráficos.

■ Conclusión

Entrené y comparé dos modelos para predecir la rotación de empleados. La **Regresión Logística** fue mejor en todas las métricas: más accuracy y, sobre todo, mejor recall y F1 para la clase `Yes` , que es la que importa si la idea es anticipar renuncias.

De todas formas, ningún modelo detecta del todo bien a los que se van. Eso pasa porque hay pocos casos `Yes` (el dataset está desbalanceado), así que a los modelos les cuesta aprender ese grupo.